

PROJECT ANALISIS DATA KATEGORIK

“Analisis Faktor-Faktor yang Mempengaruhi Penyakit Jantung Menggunakan
Regresi Logistik pada Dataset Heart Disease UCI”



Nama : Ersa Iqlima Qur'anul Ain
NIM : G1F02310031
Kelas : STATISTIKA A

**PROGRAM STUDI STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS MATARAM
2025**

A. REGRESI LOGISTIK

Regresi logistik adalah metode statistik yang digunakan untuk memodelkan hubungan antara satu variabel dependen berbentuk kategorik biner (misalnya: 0 = tidak sakit, 1 = sakit) dengan satu atau lebih variabel independen yang dapat berupa numerik maupun kategorik. Metode ini digunakan ketika tujuan analisis adalah memprediksi probabilitas suatu kejadian.

Berbeda dengan regresi linear, regresi logistik tidak memodelkan nilai Y secara langsung. Sebaliknya, regresi logistik memodelkan peluang (probability) terjadinya kategori tertentu menggunakan fungsi logit (log odds). Dengan demikian, prediksi yang dihasilkan berada dalam rentang 0 sampai 1, sesuai dengan sifat probabilitas.

Secara umum, model regresi logistik biner dinyatakan sebagai:

$$\text{logit}(p) = \ln \left(\frac{p}{1-p} \right) = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k$$

di mana:

- p adalah probabilitas bahwa $Y = 1$,
- $\frac{p}{1-p}$ adalah odds,
- $\beta_0, \beta_1, \dots, \beta_k$ adalah parameter model yang menggambarkan pengaruh setiap variabel X terhadap peluang kejadian Y.

Parameter dalam model diestimasi menggunakan metode Maximum Likelihood Estimation (MLE), yang bertujuan mencari nilai koefisien terbaik agar model memiliki peluang terbesar dalam menjelaskan data.

Koefisien regresi logistik diinterpretasikan menggunakan *Odds Ratio* (OR), yang diperoleh dari hasil eksponensial koefisien β . Jika nilai OR lebih besar dari 1, maka variabel prediktor meningkatkan peluang kejadian $Y = 1$, sedangkan OR yang lebih kecil dari 1 menunjukkan bahwa variabel tersebut menurunkan peluang $Y =$

1. Koefisien bernilai positif menunjukkan hubungan positif antara prediktor dan logit(Y), sementara koefisien negatif menunjukkan hubungan yang berlawanan arah. Interpretasi odds ratio ini banyak digunakan dalam penelitian-penelitian empiris. Sebagai contoh, Kusuma (2021) menggunakan regresi logistik multilevel untuk menganalisis determinan pekerja miskin di Sumatera Selatan dan menemukan bahwa karakteristik seperti tingkat pendidikan, status perkawinan, daerah tempat tinggal, jenis pekerjaan, dan jam kerja memiliki pengaruh signifikan terhadap peluang seseorang menjadi pekerja miskin.

Pengujian signifikansi dalam regresi logistik biasanya dilakukan melalui dua jenis uji, yaitu uji simultan dan uji parsial. Uji simultan dilakukan menggunakan *Likelihood Ratio Test* untuk menilai apakah seluruh variabel independen secara bersama-sama berpengaruh signifikan terhadap model. Jika p-value lebih kecil dari tingkat signifikansi, maka minimal terdapat satu variabel yang memiliki pengaruh terhadap variabel respon. Sementara itu, uji parsial menggunakan *Wald Test* untuk menilai signifikansi masing-masing koefisien secara individual. Selain itu, kecocokan model dapat dievaluasi menggunakan uji Hosmer–Lemeshow, yang menilai apakah model memiliki kesesuaian yang baik dengan data. Pendekatan-pendekatan ini dijelaskan secara sistematis dalam penelitian Nurrizqi et al. (2022), yang memanfaatkan regresi logistik biner berbasis *backward elimination* untuk mengidentifikasi faktor-faktor yang memengaruhi tingkat kemiskinan di Indonesia tahun 2021. Penelitian tersebut menunjukkan bahwa variabel Indeks Pembangunan Manusia (IPM) dan Gini Ratio berperan signifikan dalam menentukan kategori tingkat kemiskinan, serta menghasilkan tingkat akurasi klasifikasi sebesar 83,33 persen.

Regresi logistik juga memerlukan evaluasi performa model, yang umum dilakukan menggunakan Confusion Matrix, Akurasi, Sensitivitas, Spesifisitas, AUC, dan ROC Curve untuk mengukur kemampuan model membedakan antara dua kelas.

Secara keseluruhan, regresi logistik merupakan metode yang sangat populer karena kemampuannya dalam memprediksi probabilitas, mengklasifikasikan data, serta memberikan interpretasi yang mudah terutama dalam konteks analisis kesehatan, sosial, dan bisnis.

B. DATA SET

Pada project kali ini saya menggunakan dataset Heart Disease UCI, yaitu kumpulan data medis pasien yang memuat informasi seperti usia, tekanan darah, dan kadar kolesterol. Dataset ini dimanfaatkan untuk menganalisis dan memprediksi apakah seorang pasien berpotensi mengalami penyakit jantung atau tidak berdasarkan variabel-variabel tersebut.

<https://www.kaggle.com/datasets/mragpavank/heart-diseaseuci>

C. Exploratory Data Analysis (EDA)

```
> #MELIHAT STRUKTUR AWAL DATA
> # Melihat 6 baris pertama
> head(data)
# A tibble: 6 x 7
  age sex      cp      trestbps chol thalch oldpeak
  <dbl> <chr> <chr>      <dbl> <dbl> <dbl> <chr>
1    63 Male typical angina    145   233   150 2.3
2    67 Male asymptomatic    160   286   108 1.5
3    67 Male asymptomatic    120   229   129 2.6
4    37 Male non-anginal    130   250   187 3.5
5    41 Female atypical angina    130   204   172 1.4
6    56 Male atypical angina    120   236   178 0.8
```

Interpretasi :

Output tersebut menampilkan 6 baris pertama (head) dari sebuah dataset yang terdiri dari 6 observasi dan 7 variabel. Variabel age bertipe numerik (usia responden), sex dan cp bertipe karakter yang masing-masing merepresentasikan jenis kelamin dan tipe nyeri dada, sedangkan trestbps, chol, dan thalch bertipe numerik yang menunjukkan tekanan darah istirahat, kadar kolesterol, dan denyut jantung maksimum. Variabel oldpeak juga ditampilkan namun masih bertipe karakter, yang mengindikasikan perlu dilakukan konversi ke numerik sebelum analisis lebih lanjut. Secara umum, output ini digunakan untuk memastikan

struktur data, tipe variabel, serta memberikan gambaran awal nilai-nilai pada dataset sebelum dilakukan tahap analisis lanjutan seperti pemodelan

```
> # Melihat struktur variabel
> str(data)
tibble [920 × 7] (S3: tbl_df/tbl/data.frame)
 $ age      : num [1:920] 63 67 67 37 41 56 62 57 63 53 ...
 $ sex      : chr [1:920] "Male" "Male" "Male" "Male" ...
 $ cp       : chr [1:920] "typical angina" "asymptomatic" "asymptomatic" "non-anginal" ...
 $ trestbps : num [1:920] 145 160 120 130 130 120 140 120 130 140 ...
 $ chol     : num [1:920] 233 286 229 250 204 236 268 354 254 203 ...
 $ thalch   : num [1:920] 150 108 129 187 172 178 160 163 147 155 ...
 $ oldpeak  : chr [1:920] "2.3" "1.5" "2.6" "3.5" ...
```

Interpretasi :

Hasil tersebut menunjukkan bahwa dataset berbentuk tibble dengan 920 observasi dan 7 variabel. Variabel age, trestbps, chol, dan thalch bertipe numerik (num), sehingga siap digunakan untuk analisis kuantitatif. Variabel sex dan cp bertipe karakter (chr) yang merepresentasikan kategori jenis kelamin dan tipe nyeri dada. Sementara itu, variabel oldpeak masih bertipe karakter, padahal secara konsep merupakan variabel numerik (depresi segmen ST), sehingga perlu dilakukan konversi ke tipe numerik sebelum dilakukan analisis lanjutan seperti pemodelan regresi atau klasifikasi. Hasil ini menegaskan struktur data dan kesesuaian tipe variabel sebagai tahap awal sebelum preprocessing lebih lanjut.

```
> # Melihat ringkasan statistik
> summary(data)
```

age	sex	cp	trestbps	chol
Min. :28.00	Length:920	Length:920	Min. : 0.0	Min. : 0.0
1st Qu.:47.00	Class :character	Class :character	1st Qu.:120.0	1st Qu.:175.0
Median :54.00	Mode :character	Mode :character	Median :130.0	Median :223.0
Mean :53.51			Mean :132.1	Mean :199.1
3rd Qu.:60.00			3rd Qu.:140.0	3rd Qu.:268.0
Max. :77.00			Max. :200.0	Max. :603.0
			NA's :59	NA's :30

thalch	oldpeak
Min. : 60.0	Length:920
1st Qu.:120.0	Class :character
Median :140.0	Mode :character
Mean :137.5	
3rd Qu.:157.0	
Max. :202.0	
NA's :55	

Interpretasi :

Hasil summary(data) memberikan gambaran ringkas statistik deskriptif untuk setiap variabel. Variabel age memiliki rentang usia 28–77 tahun dengan median 54

tahun dan rata-rata 53,51 tahun, yang menunjukkan bahwa mayoritas responden berada pada usia paruh baya. Variabel trestbps memiliki median 130 mmHg dan rata-rata 132,1 mmHg, dengan nilai maksimum mencapai 200 serta terdapat 59 data hilang (NA). Variabel chol memiliki median 223 dan rata-rata 199,1, dengan sebaran cukup lebar hingga nilai maksimum 603 serta 30 data hilang. Variabel thalch menunjukkan denyut jantung maksimum dengan median 140 dan rata-rata 137,5, serta terdapat 55 data hilang. Sementara itu, variabel sex, cp, dan oldpeak masih bertipe karakter sehingga hanya ditampilkan informasi panjang dan kelas data, bukan statistik numerik. Secara keseluruhan, output ini menunjukkan adanya missing value pada beberapa variabel numerik serta perlunya konversi tipe data, khususnya pada variabel oldpeak, sebelum dilakukan analisis atau pemodelan lebih lanjut.

```
> #CEK MISSING VALUE
> # Total missing value tiap kolom
> colSums(is.na(data))
  age      sex      cp trestbps      chol      thalch      oldpeak
  0         0         0        59        30        55         62

> # Menangani NA:
> # - Numerik diisi median
> # - Kategorik diisi modus
> data_clean <- data %>%
+   mutate(across(where(is.numeric), ~ ifelse(is.na(.), median(., na.rm = TRUE), .))) %>%
+   mutate(across(where(is.factor), ~ ifelse(is.na(.), mode_func(., .)))
> # Cek setelah pembersihan
> colSums(is.na(data_clean))
  age      sex      cp trestbps      chol      thalch      oldpeak
  0         0         0         0         0         0         62
```

Interpretasi :

Hasil pengecekan *missing value* menunjukkan bahwa sebelum pembersihan data, variabel trestbps memiliki 59 nilai hilang, chol 30 nilai hilang, thalch 55 nilai hilang, dan oldpeak 62 nilai hilang, sedangkan variabel age, sex, dan cp tidak memiliki data hilang. Selanjutnya, dilakukan penanganan *missing value* dengan mengisi variabel numerik menggunakan nilai median dan variabel kategorik menggunakan modus. Setelah proses pembersihan, seluruh variabel numerik telah bebas dari nilai hilang. Namun, variabel oldpeak masih menunjukkan 62 nilai hilang, yang mengindikasikan bahwa variabel tersebut belum dikenali sebagai

numerik atau faktor sehingga belum terjangkau oleh proses imputasi. Hal ini menunjukkan perlunya konversi tipe data *oldpeak* ke numerik terlebih dahulu agar *missing value* pada variabel tersebut dapat ditangani dengan tepat sebelum analisis lanjutan dilakukan.

```
> # CEK OUTLIER DENGAN IQR
> # Menampilkan jumlah outlier tiap variabel numerik
> check_outlier <- function(x) {
+   Q1 <- quantile(x, 0.25, na.rm = TRUE)
+   Q3 <- quantile(x, 0.75, na.rm = TRUE)
+   IQR_value <- IQR(x, na.rm = TRUE)
+   lower <- Q1 - 1.5 * IQR_value
+   upper <- Q3 + 1.5 * IQR_value
+   sum(x < lower | x > upper, na.rm = TRUE)
+ }
> sapply(data_clean %>% select_if(is.numeric), check_outlier)
      age trestbps      chol    thalch
      0         28      185         2
> handle_outlier <- function(x) {
+   Q1 <- quantile(x, 0.25, na.rm = TRUE)
+   Q3 <- quantile(x, 0.75, na.rm = TRUE)
+   IQR_value <- IQR(x, na.rm = TRUE)
+   lower <- Q1 - 1.5 * IQR_value
+   upper <- Q3 + 1.5 * IQR_value
+
+   x[x < lower] <- lower
+   x[x > upper] <- upper
+   return(x)
+ }
> data_no_outlier <- data_clean %>%
+   mutate(across(where(is.numeric), handle_outlier))
> #Cek Ulang Outlier Setelah Ditangani
> sapply(data_no_outlier %>% select_if(is.numeric), check_outlier)
      age trestbps      chol    thalch
      0         0         0         0
```

Interpretasi :

Hasil deteksi *outlier* menggunakan metode Interquartile Range (IQR) menunjukkan bahwa sebelum penanganan, variabel *trestbps* memiliki 28 *outlier*, *chol* memiliki *outlier* paling banyak yaitu 185, dan *thalch* memiliki 2 *outlier*, sementara variabel *age* tidak terdeteksi memiliki *outlier*. Selanjutnya dilakukan penanganan *outlier* dengan metode capping (winsorizing), yaitu mengganti nilai yang berada di bawah batas bawah ($Q1 - 1,5 \text{ IQR}$) dan di atas batas atas ($Q3 + 1,5 \text{ IQR}$) menjadi nilai batas tersebut. Setelah proses ini diterapkan, pengecekan ulang menunjukkan bahwa seluruh variabel numerik (*age*, *trestbps*, *chol*, *thalch*) sudah tidak memiliki *outlier*. Hal ini mengindikasikan bahwa proses penanganan *outlier* berhasil menormalkan sebaran data numerik sehingga data menjadi lebih stabil dan siap digunakan untuk analisis atau pemodelan lanjutan.

```
> #STATISTIK DESKRIPTIF
> skim(data)
```

```
— Data Summary
```

Name	data
Number of rows	920
Number of columns	7

```
Column type frequency:
```

character	3
numeric	4

```
Group variables
```

None

```
— Variable type: character
```

	skim_variable	n_missing	complete_rate	min	max	empty	n_unique	whitespace
1	sex	0	1	4	6	0	2	0
2	cp	0	1	11	15	0	4	0
3	oldpeak	62	0.933	1	4	0	53	0

```
— Variable type: numeric
```


	skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100	hist
1	age	0	1	53.5	9.42	28	47	54	60	77	
2	trestbps	59	0.936	132.	19.1	0	120	130	140	200	
3	chol	30	0.967	199.	111.	0	175	223	268	603	
4	thalch	55	0.940	138.	25.9	60	120	140	157	202	

Interpretasi :

Hasil tersebut memberikan ringkasan statistik deskriptif yang komprehensif terhadap dataset. Data terdiri dari 920 observasi dan 7 variabel, dengan 3 variabel bertipe karakter (sex, cp, dan oldpeak) serta 4 variabel numerik (age, trestbps, chol, dan thalch). Variabel karakter sex dan cp tidak memiliki nilai hilang, sedangkan oldpeak memiliki 62 nilai hilang dengan tingkat kelengkapan data sebesar 93,3% dan jumlah nilai unik yang cukup besar, yang mengindikasikan bahwa variabel ini seharusnya bertipe numerik. Pada variabel numerik, age tidak memiliki *missing value* dengan rata-rata 53,5 dan sebaran usia 28–77 tahun. Variabel trestbps, chol, dan thalch masing-masing memiliki nilai hilang sebanyak 59, 30, dan 55, dengan sebaran data yang cukup lebar, khususnya chol yang menunjukkan variasi besar hingga nilai maksimum 603. Secara keseluruhan, output ini menegaskan adanya ketidaksesuaian tipe data pada variabel oldpeak serta keberadaan missing value pada beberapa variabel numerik

Visualisasi Data


a. Histogram Untuk Variabel Age



Interpretasi :

Histogram variabel age menunjukkan bahwa distribusi usia responden berada pada kisaran sekitar 28 hingga 77 tahun, dengan sebagian besar data terkonsentrasi pada rentang usia 45 hingga 65 tahun. Pola distribusinya tampak mendekati normal, ditandai dengan bentuk menyerupai lonceng (bell-shaped curve) dengan puncak frekuensi pada usia sekitar 50–60 tahun. Frekuensi usia muda (di bawah 40 tahun) maupun usia lanjut (di atas 70 tahun) terlihat jauh lebih rendah dibandingkan kelompok usia tengah. Hal ini menunjukkan bahwa mayoritas responden dalam dataset merupakan individu usia paruh baya hingga lanjut awal, sehingga analisis selanjutnya perlu mempertimbangkan dominasi kelompok usia tersebut.


b. Pie Chart Untuk Variabel Sex



Interpretasi :

Pie chart variabel sex menunjukkan bahwa proporsi jenis kelamin dalam dataset sangat tidak seimbang. Sebagian besar responden adalah laki-laki, yaitu sebesar 78,9%, sedangkan responden perempuan hanya berjumlah 21,1%. Ketidakseimbangan distribusi ini mengindikasikan bahwa laki-laki mendominasi sampel penelitian. Kondisi ini penting diperhatikan karena komposisi gender yang tidak merata dapat memengaruhi hasil analisis, terutama apabila variabel sex berkaitan dengan variabel target atau variabel lainnya dalam penelitian.

c. Bar Chart Untuk Variabel Chest Pain Type (CP)



Interpretasi :

Bar chart variabel CP (Chest Pain Type) menunjukkan bahwa mayoritas responden dalam dataset berada pada kategori nyeri dada asymptomatic, yaitu sebanyak 496 orang, yang berarti sebagian besar pasien tidak merasakan nyeri dada meskipun berpotensi memiliki penyakit jantung. Kategori terbanyak berikutnya adalah non-anginal pain dengan jumlah 204 orang, diikuti oleh atypical angina sebanyak 174 orang. Sementara itu, kategori typical angina memiliki frekuensi paling sedikit, yaitu hanya 46 orang. Distribusi ini menunjukkan bahwa kasus nyeri dada khas (typical angina) relatif jarang, sedangkan kondisi tanpa gejala (asymptomatic) mendominasi. Ketimpangan distribusi ini penting diperhatikan dalam analisis lebih lanjut karena jenis nyeri dada merupakan salah satu variabel penting dalam memprediksi adanya penyakit jantung.

D. ANALISIS DATA KATEGORIK

1. Model regresi logistic.

Regresi logistik merupakan metode analisis statistik yang digunakan untuk memodelkan hubungan antara satu variabel dependen bersifat kategorik (umumnya biner) dengan satu atau lebih variabel independen yang dapat berupa numerik maupun kategorik. Berbeda dengan regresi linear yang memodelkan nilai rata-rata variabel respon, regresi logistik memodelkan peluang (probabilitas) terjadinya suatu kejadian tertentu.

Proses mencari β dilakukan dengan menggunakan software R, berikut adalah outputnya :

Coefficients:				
	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.762e+01	2.400e+03	-0.007	0.99414
age	7.857e-04	9.238e-03	0.085	0.93222
sexMale	-5.132e-01	1.805e-01	-2.843	0.00447 **
cptypical angina	1.970e-01	2.152e-01	0.915	0.35995
cpnon-anginal	-3.737e-01	2.073e-01	-1.803	0.07134 .
cptypical angina	-4.158e-01	3.899e-01	-1.066	0.28621
trestbps	7.787e-03	4.617e-03	1.687	0.09170 .
thalch	7.573e-03	3.452e-03	2.193	0.02827 *

Berdasarkan hasil estimasi regresi logistik, diperoleh bahwa variabel jenis kelamin (sexMale) dan denyut jantung maksimum (thalch) berpengaruh signifikan terhadap peluang individu termasuk ke dalam kelompok target pada tingkat signifikansi 5%. Variabel sexMale memiliki koefisien negatif sebesar -0,513 dengan nilai p sebesar 0,00447, yang menunjukkan bahwa individu berjenis kelamin laki-laki memiliki peluang yang lebih rendah untuk termasuk ke dalam kelompok target dibandingkan individu perempuan, dengan asumsi variabel lain konstan. Sementara itu, variabel thalch memiliki koefisien positif sebesar 0,007573 dan signifikan ($p = 0,02827$), yang mengindikasikan bahwa peningkatan denyut jantung maksimum cenderung meningkatkan peluang individu termasuk ke dalam kelompok target.

Variabel cp non-anginal dan trestbps menunjukkan pengaruh yang mendekati signifikan pada taraf 10%, dengan nilai p masing-masing sebesar 0,07134 dan 0,09170. Hal ini mengindikasikan bahwa kedua variabel tersebut berpotensi memengaruhi peluang kejadian, meskipun bukti statistiknya belum cukup kuat pada taraf signifikansi 5%. Sementara itu, variabel age, cp atypical angina, dan cp typical angina tidak menunjukkan pengaruh yang signifikan secara statistik karena memiliki nilai p lebih besar dari 0,05.

Nilai konstanta (intercept) tidak signifikan, yang menunjukkan bahwa ketika seluruh variabel independen bernilai nol, peluang kejadian tidak dapat dijelaskan secara bermakna oleh model. Secara keseluruhan, hasil ini menunjukkan bahwa faktor fisiologis tertentu, khususnya jenis kelamin dan denyut jantung maksimum, memiliki peran penting dalam memengaruhi probabilitas individu termasuk dalam kelompok target berdasarkan model regresi logistik yang dibangun.

2. Odds ratio

Odds Ratio (OR) merupakan ukuran yang digunakan dalam regresi logistik untuk menggambarkan seberapa besar perubahan peluang (odds) terjadinya suatu kejadian akibat perubahan satu satuan pada variabel independen, dengan asumsi variabel lain bersifat konstan. Odds didefinisikan sebagai perbandingan antara probabilitas terjadinya suatu kejadian dengan probabilitas tidak terjadinya kejadian tersebut. Nilai Odds Ratio diperoleh dengan mengeksponensialkan koefisien regresi logistik.

Secara matematis, Odds Ratio dirumuskan sebagai:

$$OR = e^{\beta}$$

di mana β merupakan koefisien regresi logistik dari masing-masing variabel independen.

Nilai Odds Ratio memiliki interpretasi sebagai berikut:

- $OR > 1$ menunjukkan bahwa variabel tersebut meningkatkan peluang terjadinya kejadian.

- $OR < 1$ menunjukkan bahwa variabel tersebut menurunkan peluang terjadinya kejadian.
- $OR = 1$ menunjukkan bahwa variabel tersebut tidak memberikan pengaruh terhadap peluang kejadian.

Selain itu, interpretasi Odds Ratio umumnya dilengkapi dengan interval kepercayaan 95% (CI 95%). Jika interval kepercayaan tidak meliputi nilai 1, maka pengaruh variabel tersebut dianggap signifikan secara statistik.

Berdasarkan hasil estimasi regresi logistik, diperoleh nilai Odds Ratio untuk masing-masing variabel independen sebagai berikut.

```
> OR_table
# A tibble: 60 x 7
```

term <chr>	estimate <dbl>	std.error <dbl>	statistic <dbl>	p.value <dbl>	conf.low <dbl>	conf.high <dbl>
1 (Intercept)	0.0000000224	2400.	-0.00734	0.994	NA	1.35e+204
2 age	1.00	0.00924	0.0850	0.932	9.83e- 1	1.02e+ 0
3 sexMale	0.599	0.181	-2.84	0.00447	4.20e- 1	8.52e- 1
4 cpatypical angina	1.22	0.215	0.915	0.360	7.98e- 1	1.86e+ 0
5 cpnon-anginal	0.688	0.207	-1.80	0.0713	4.56e- 1	1.03e+ 0
6 cptypical angina	0.660	0.390	-1.07	0.286	3.01e- 1	1.40e+ 0
7 trestbps	1.01	0.00462	1.69	0.0917	9.99e- 1	1.02e+ 0
8 thalch	1.01	0.00345	2.19	0.0283	1.00e+ 0	1.01e+ 0
9 oldpeak-0.5	1.06	2939.	0.0000197	1.00	2.85e- 8	2.67e+ 7
10 oldpeak-0.7	0.460	3393.	-0.000229	1.00	1.70e-10	1.30e+ 9

Berdasarkan hasil perhitungan Odds Ratio yang ditampilkan pada Tabel Odds Ratio, dapat diketahui bahwa beberapa variabel memiliki pengaruh yang signifikan terhadap peluang individu termasuk ke dalam kelompok target. Variabel jenis kelamin (sexMale) memiliki nilai Odds Ratio sebesar 0,599 dengan nilai *p-value* sebesar 0,00447 dan interval kepercayaan 95% yang tidak mencakup nilai satu. Hal ini menunjukkan bahwa individu berjenis kelamin laki-laki memiliki peluang sebesar 0,599 kali dibandingkan perempuan untuk termasuk ke dalam kelompok target, dengan asumsi variabel lain konstan. Dengan kata lain, jenis kelamin laki-laki cenderung menurunkan peluang kejadian.

Variabel denyut jantung maksimum (thalch) juga menunjukkan pengaruh yang signifikan secara statistik dengan nilai Odds Ratio sebesar 1,01 dan *p-value* sebesar 0,0283. Hal ini mengindikasikan bahwa setiap peningkatan satu satuan

denyut jantung maksimum akan meningkatkan peluang individu termasuk ke dalam kelompok target sebesar 1,01 kali, dengan asumsi variabel lain tetap.

Variabel tekanan darah istirahat (trestbps) dan tipe nyeri dada non-anginal (cp non-anginal) menunjukkan pengaruh yang mendekati signifikan pada taraf signifikansi 10%, masing-masing dengan nilai *p-value* sebesar 0,0917 dan 0,0713. Meskipun demikian, kedua variabel tersebut belum dapat dinyatakan signifikan secara statistik pada taraf 5% karena interval kepercayaan 95% masih mencakup nilai satu.

Sementara itu, variabel usia (age), cp atypical angina, dan cp typical angina memiliki nilai Odds Ratio yang mendekati satu serta *p-value* yang lebih besar dari 0,05, sehingga dapat disimpulkan bahwa variabel-variabel tersebut tidak berpengaruh signifikan terhadap peluang kejadian. Nilai Odds Ratio yang mendekati satu menunjukkan bahwa perubahan pada variabel tersebut tidak memberikan perubahan peluang yang berarti terhadap kejadian yang diamati.

Secara keseluruhan, hasil analisis Odds Ratio menunjukkan bahwa jenis kelamin dan denyut jantung maksimum merupakan faktor utama yang berpengaruh signifikan terhadap peluang kejadian, sedangkan variabel lainnya belum menunjukkan pengaruh yang cukup kuat secara statistik berdasarkan model regresi logistik yang dibangun.

3. Pehitungan Probability P(X)

Probability P(X) dalam regresi logistik merupakan probabilitas bersyarat yang menyatakan peluang suatu individu termasuk ke dalam kelompok target ($Y = 1$) berdasarkan nilai variabel-variabel independen yang dimilikinya. Probability ini diperoleh dengan mentransformasikan fungsi logit ke dalam fungsi logistik sehingga menghasilkan nilai probabilitas yang berada pada rentang 0 hingga 1.

Secara matematis, Probability P(X) dirumuskan sebagai:

$$P(Y = 1 | X) = \frac{e^{\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k}}{1 + e^{\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k}}$$

Nilai Probability P(X) dihitung menggunakan fungsi prediksi pada model regresi logistik yang telah diestimasi. Hasil prediksi ini menunjukkan peluang masing-masing observasi untuk termasuk ke dalam kelompok target berdasarkan kombinasi variabel independen yang digunakan dalam model. Berdasarkan hasil perhitungan Probability P(X) menggunakan model regresi logistik, diperoleh nilai probabilitas untuk masing-masing observasi yang bervariasi. Cuplikan hasil Probability P(X) ditunjukkan pada tabel hasil prediksi, yang memuat nilai probabilitas dan kelas target aktual.

	Probability	target
	<i><dbl></i>	<i><fct></i>
1	0.0000000507	0
2	0.317	1
3	0.244	0
4	0.584	1
5	0.590	0
6	0.724	0

Berdasarkan output Probability P(X) yang diperoleh, pada observasi pertama nilai probabilitas sebesar 0,0000000507 menunjukkan peluang yang sangat rendah bagi individu tersebut untuk termasuk ke dalam kelompok target. Hal ini sejalan dengan nilai target aktual yang bernilai 0, sehingga model mampu memberikan prediksi yang tepat pada observasi tersebut. Pada observasi kedua, nilai probabilitas sebesar 0,317 menunjukkan peluang yang relatif rendah, namun individu tersebut memiliki nilai target aktual 1, yang mengindikasikan bahwa model belum mampu mengklasifikasikan observasi ini secara tepat.

Pada observasi ketiga, nilai probabilitas sebesar 0,244 menunjukkan peluang yang rendah dan sesuai dengan nilai target aktual 0. Selanjutnya, pada observasi keempat diperoleh nilai probabilitas sebesar 0,584, yang menunjukkan peluang lebih besar dari 0,5 untuk termasuk ke dalam kelompok target dan konsisten dengan nilai target aktual sebesar 1. Pada observasi kelima, meskipun nilai probabilitas relatif tinggi yaitu 0,590, individu tersebut memiliki nilai target aktual 0, sehingga terjadi ketidaksesuaian antara hasil

prediksi dan kondisi aktual. Sementara itu, pada observasi keenam diperoleh nilai probabilitas sebesar 0,724, yang menunjukkan peluang tinggi untuk termasuk ke dalam kelompok target, meskipun nilai target aktual tercatat 0.

E. KESIMPULAN

Berdasarkan hasil analisis data kategorik menggunakan regresi logistik pada dataset *Heart Disease UCI*, dapat disimpulkan bahwa regresi logistik merupakan metode yang sesuai untuk memodelkan hubungan antara variabel-variabel klinis dengan peluang seseorang termasuk ke dalam kelompok target. Tahapan awal analisis melalui Exploratory Data Analysis (EDA) menunjukkan adanya perbedaan tipe variabel, missing value, dan outlier yang perlu ditangani terlebih dahulu agar data layak digunakan dalam pemodelan. Proses pembersihan data yang dilakukan menghasilkan dataset yang lebih stabil dan siap untuk dianalisis lebih lanjut.

Hasil pemodelan regresi logistik menunjukkan bahwa tidak semua variabel independen memberikan pengaruh yang signifikan terhadap peluang kejadian. Variabel jenis kelamin dan denyut jantung maksimum terbukti berpengaruh signifikan pada taraf signifikansi 5%, di mana jenis kelamin laki-laki cenderung menurunkan peluang individu termasuk ke dalam kelompok target, sedangkan peningkatan denyut jantung maksimum meningkatkan peluang tersebut. Sementara itu, variabel usia, tipe nyeri dada, dan tekanan darah istirahat tidak menunjukkan pengaruh yang signifikan secara statistik, meskipun beberapa variabel memiliki kecenderungan pengaruh pada taraf signifikansi yang lebih longgar.

Interpretasi hasil melalui Odds Ratio dan Probability $P(X)$ memberikan gambaran yang lebih jelas mengenai arah dan besar pengaruh masing-masing variabel serta peluang kejadian pada tingkat individu. Nilai Probability $P(X)$ menunjukkan variasi peluang yang cukup beragam antar individu, namun masih ditemukan beberapa ketidaksesuaian antara prediksi dan kondisi aktual. Hal ini menunjukkan bahwa meskipun model regresi logistik mampu memberikan estimasi probabilitas yang informatif, evaluasi performa model lebih lanjut masih diperlukan untuk meningkatkan kemampuan klasifikasi pada penelitian selanjutnya.

Referensi

- Nurrizqi, A. I., Erfiani, Indahwati, Fitrianto, A., & Amelia, R. (2022). *Pemodelan regresi logistik berbasis backward elimination untuk mengetahui faktor yang memengaruhi tingkat kemiskinan di Indonesia tahun 2021*. Jurnal Statistika dan Aplikasinya, 6(2), 160–170. <https://doi.org/10.2620-8369>
- Kusuma, G. W. (2021). *Determinan Pekerja Miskin di Provinsi Sumatera Selatan Tahun 2020 dengan Regresi Multilevel Logistik Biner*. Jurnal Statistika dan Aplikasinya, 19(8), 198–207.
- Pranav, K. (2020). *Heart Disease UCI* [Dataset]. Kaggle. <https://www.kaggle.com/datasets/pranavraikokte/heart-disease-uci>